

Analiza strukture ličnosti primenom metoda klasterovanja

Projekat iz Istraživanja podataka 2 [R275]

Ksenija Ivanović 135/2019

Školska 2025/26 godina

Sadržaj

1	Uvod	2
1.1	Opis problema	2
1.2	Cilj rada	2
2	Opis podataka	3
2.1	Struktura upitnika	3
2.2	Dodatne promenljive	3
3	Metodologija	4
3.1	Priprema podataka	4
4	Pretprocesiranje podataka	4
4.1	Učitavanje i filtriranje podataka	4
4.2	Izbor relevantnih promenljivih	4
4.3	Standardizacija podataka	5
5	Redukcija dimenzionalnosti – PCA analiza	5
5.1	PCA bez vremenskih promenljivih	5
5.2	PCA sa vremenskim promenljivama	5
6	Algoritmi klasterovanja	6
6.1	Klasterovanje – KMeans	6
6.1.1	Rezultati klasterovanja	7
6.1.2	Evaluacija klastera	7
6.2	Evaluacija rezultata	8
7	Rezultati	8
8	Diskusija	8
9	Zaključak	8

1 Uvod

1.1 Opis problema

U ovom radu analiziramo podatke prikupljene putem Big Five Personality testa, jednog od najuticajnijih i empirijski najpotvrđenijih modela ličnosti u savremenoj psihologiji. Model opisuje ličnost kroz pet osnovnih dimenzija:


- Ekstraverzija (Extraversion)
- Neuroticizam (Neuroticism)
- Prijatnost (Agreeableness)
- Savesnost (Conscientiousness)
- Otvorenost ka iskustvu (Openness to Experience)

Svaka dimenzija meri se pomoću više tvrdnji koje ispitanici ocenjuju na Likertovoj skali (od 1 do 5). Agregacijom odgovora dobija se numerički skor koji predstavlja izraženost određene osobine kod pojedinca.

Iako se osobine ličnosti tradicionalno posmatraju kao kontinuirane dimenzije, postavlja se pitanje da li se ispitanici mogu prirodno grupisati u određene tipove ličnosti. Drugim rečima, da li u podacima postoji latentna struktura koja ukazuje na postojanje relativno stabilnih grupa pojedinaca sa sličnim profilima osobina?

Big Five Personality Test

Your Big Five scores are:



Slika 1: Primer prikaza rezultata Big Five testa

Ovaj rad ima za cilj da ispita postojanje takve strukture primenom metoda nenadgledanog učenja.

1.2 Cilj rada

Cilj rada je da se ispita da li se na osnovu odgovora na Big Five test može identifikovati prirodna segmentacija ispitanika.

Konkretnije, cilj je:

- utvrditi da li postoji jasno izražena klasterka struktura u podacima,
- uporediti performanse različitih algoritama klasterovanja,
- interpretirati dobijene klastere na osnovu prosečnih vrednosti osobina.

2 Opis podataka

Podaci koji se analiziraju prikupljeni su u periodu 2016–2018. godine putem interaktivnog onlajn testa ličnosti. Test je konstruisan na osnovu *Big-Five Factor Markers* iz IPIP baze (International Personality Item Pool).

Ispitanici su na početku testa informisani da će njihovi odgovori biti sačuvani i korišćeni u istraživačke svrhe, a na kraju su morali da potvrde saglasnost za korišćenje podataka. U dataset su uključeni isključivo ispitanici koji su dali saglasnost.

2.1 Struktura upitnika

Upitnik se sastoji od 50 tvrdnji, po 10 za svaku od pet dimenzija ličnosti:

- Ekstraverzija (EXT),
- Neuroticizam / Emocionalna stabilnost (EST),
- Saradljivost (AGR),
- Savesnost (CSN),
- Otvorenost ka iskustvu (OPN).

Svaka tvrdnja ocenjena je na petostepenoj Likertovoj skali:

$$1 = \text{Disagree}, \quad 3 = \text{Neutral}, \quad 5 = \text{Agree}.$$

Pored samih odgovora, zabeleženo je i vreme odgovaranja na svako pitanje (u milisekundama), što omogućava dodatne analize ponašanja ispitanika tokom popunjavanja testa.

2.2 Dodatne promenljive

Dataset sadrži i sledeće tehničke i kontekstualne informacije:

- `dateload` – vremenska oznaka početka testa,
- `introelapse`, `testelapse`, `endelapse` – vreme provedeno na pojedinim delovima testa,
- `IPC` – broj zapisa sa iste IP adrese (radi kontrole višestrukih unosa),
- `country` – zemlja korisnika (određena tehničkim putem),
- `screenw`, `screenh` – dimenzije ekrana,

- približne geografske koordinate (latitude i longitude), uz napomenu da ove vrednosti nisu precizne.

U okviru analize, primarni fokus biće na odgovorima na tvrdnje (50 stavki), dok će dodatne promenljive biti korišćene za filtriranje i inicijalnu obradu podataka (npr. uklanjanje višestrukih unosa korišćenjem promenljive IPC).

3 Metodologija

3.1 Priprema podataka

Pre primene algoritama klasterovanja izvršeni su sledeći koraci:

- Provera i uklanjanje nedostajućih vrednosti.
- Eventualna agregacija odgovora po dimenzijama.
- Skaliranje numeričkih podataka radi ujednačavanja opsega vrednosti.

Skaliranje je posebno važno jer većina algoritama klasterovanja koristi udaljenosti između tačaka, te različiti opsezi varijabli mogu značajno uticati na rezultate.

4 Pretprocesiranje podataka

Pre same primene algoritama klasterovanja izvršena je detaljna priprema podataka.

4.1 Učitavanje i filtriranje podataka

Podaci su učitani iz fajla `data-final.csv`, koji sadrži 1 015 341 ispitanika(redova) i 110 promenljivih(kolona).

Radi povećanja kvaliteta podataka, zadržani su samo ispitanici kod kojih je promenljiva IPC jednaka 1. Ova promenljiva označava broj zapisa sa iste IP adrese, te se njenim filtriranjem uklanjaju potencijalni višestruki unosi.

Nakon filtriranja, dataset je smanjen na 696 845 zapisa.

4.2 Izbor relevantnih promenljivih

Iz originalnog skupa podataka izdvojene su isključivo tvrdnje koje pripadaju pet dimenzija ličnosti (EXT, EST, AGR, CSN, OPN).

Prvo su izdvojene kolone koje predstavljaju same odgovore ispitanika (bez vremenskih oznaka odgovaranja, koje se završavaju sa _E). Time je dobijen skup od 50 promenljivih, odnosno po 10 za svaku dimenziju.

Nakon toga uklonjeni su redovi koji sadrže isključivo nedostajuće vrednosti. Nakon ovog koraka, dataset sadrži 695 704 ispitanika i 50 promenljivih.

Pored toga, formiran je i prošireni skup podataka koji uključuje i vremenske promenljive odgovaranja (kolone koje se završavaju sa _E). Na taj način dobijen je skup od 100 promenljivih, koji omogućava ispitivanje da li vreme odgovaranja utiče na formiranje klastera.

4.3 Standardizacija podataka

Pre primene algoritama klasterovanja izvršena je standardizacija svih numeričkih promenljivih korišćenjem metode Z-transformacije (StandardScaler).

Standardizacijom se svaka promenljiva transformiše tako da ima srednju vrednost 0 i standardnu devijaciju 1:

$$z = \frac{x - \mu}{\sigma}$$

Ovaj korak je neophodan jer algoritmi klasterovanja koriste mere udaljenosti između tačaka, te bi promenljive sa većim opsegom vrednosti imale veći uticaj na rezultat ukoliko ne bi bile skalirane.

Standardizacija je izvršena posebno za:

- skup od 50 psiholoških stavki,
- prošireni skup od 100 promenljivih (uključujući vreme odgovaranja).

5 Redukcija dimenzionalnosti – PCA analiza

Radi vizuelizacije strukture podataka primenjena je analiza glavnih komponenti (Principal Component Analysis – PCA).

PCA predstavlja metodu redukcije dimenzionalnosti kojom se originalne promenljive transformišu u novi skup međusobno nekorelisanih komponenti. Prva glavna komponenta (PC1) objašnjava najveći deo ukupne varijanse podataka, dok druga komponenta (PC2) objašnjava sledeći najveći deo varijanse.

U ovoj analizi izvršena je redukcija na dve glavne komponente, kako bi se omogućila dvodimenzionalna vizuelizacija podataka.


5.1 PCA bez vremenskih promenljivih

Prvo je PCA primenjena na standardizovani skup od 50 psiholoških stavki (bez vremenskih oznaka odgovaranja).

5.2 PCA sa vremenskim promenljivama

Zatim je ista procedura primenjena na prošireni skup podataka koji uključuje i vremenske promenljive odgovaranja (ukupno 100 promenljivih).

Na slici su prikazane projekcije ispitanika u prostoru prve dve glavne komponente za oba slučaja.



Slika 2: Poređenje PCA projekcija bez i sa vremenskim promenljivama

Sa slike se može primetiti:

- Projekcija bez vremenskih promenljivih prikazuje raspodelu ispitanika samo prema njihovim psihološkim osobinama.
- Projekcija sa vremenskim promenljivama može blago promeniti oblik klastera, ali u ovoj analizi vremenske promenljive nemaju dominantan uticaj.

Ovaj korak je važan jer nam omogućava da:

- vizuelno sagledamo da li se ispitanici prirodno grupišu,
- procenimo koliko vreme odgovaranja utiče na raspodelu u prostoru glavnih komponenti,
- pripremimo podatke za sledeći korak – primenu algoritama klasterovanja.

6 Algoritmi klasterovanja

U radu su primenjeni sledeći algoritmi:

- K-means klasterovanje
- Hijerarhijsko (agglomerativno) klasterovanje
- DBSCAN
- Spektralno klasterovanje

Za algoritme koji zahtevaju unapred definisan broj klastera testirano je više vrednosti parametra k , kako bi se procenila stabilnost rezultata.

6.1 Klasterovanje – KMeans

Da bismo istražili da li se ispitanici prirodno grupišu, primenili smo algoritam **KMeans** na standardizovane podatke.


Parametri: Broj klastera je postavljen na $k = 5$, sa `random_state=42` radi reproduktivnosti.

6.1.1 Rezultati klasterovanja

KMeans je primenjen na:

1. skup od 50 psiholoških stavki (bez vremenskih promenljivih),
2. prošireni skup od 100 promenljivih (uključujući vreme odgovaranja).

Labele klastera dodate su PCA DataFrame-ovima kako bismo mogli vizualizovati raspodelu u prostoru prve dve glavne komponente.



Slika 3: KMeans klasteri ($k = 5$) – poređenje bez i sa vremenskim promenljivama odgovaranja

6.1.2 Evaluacija klastera

Za ocenu kvaliteta klastera korišćene su sledeće metrike:

- **Silhouette score:** meri koliko su tačke unutar klastera slične, a između klastera različite.
- **Davies-Bouldin score:** niži skor označava bolje odvojene klasterove.
- **Calinski-Harabasz score:** veći skor označava bolje definisane klasterove.

Rezultati za uzorak od 15 000 ispitanika:

Skup podataka	Silhouette	Davies-Bouldin	Calinski-Harabasz
Bez vremenskih promenljivih	0.051	2.94	880.6
Sa vremenskim promenljivim	0.048	3.07	238.1

Tumačenje: Rezultati deluju loše jer algoritam KMeans forsira postojanje klastera čak i kada prirodno nisu jasno izraženi. To je tipično za podatke prikupljene po Big Five modelu, gde se osobine posmatraju kao kontinuirane dimenzije, a ne kao strogi tipovi ličnosti. Primetno je da uključivanje vremenskih promenljivih (`_E`) donekle menja raspodelu klastera, ali ne dramatično.

Napomena o broju klastera: Eksperimenti sa $k = 4$ mogu dati jasnije granice između klastera, jer peti klaster samo razblažuje centralne tačke.

6.2 Evaluacija rezultata

Rezultati klasterovanja upoređeni su korišćenjem sledećih metrika:

- Silhouette indeks
- Davies–Bouldin indeks
- Calinski–Harabasz indeks

Na osnovu ovih metrika vršeno je poređenje algoritama i izbor modela koji najbolje opisuje strukturu podataka.

7 Rezultati

U ovom poglavlju biće prikazani:

- Tabele sa vrednostima evaluacionih metrika.
- Vizualizacije klastera pomoću PCA projekcije.
- Heatmap prikaz prosečnih vrednosti osobina po klasterima.

Na osnovu ovih rezultata izvršiće se interpretacija dobijenih grupa ispitanika.

8 Diskusija

U ovom delu rada razmatra se:

- Da li postoji jasna prirodna struktura u podacima.
- Koliko su klasteri stabilni i interpretabilni.
- Ograničenja primenjenog pristupa.

9 Zaključak

U zaključku će biti sumirani ključni nalazi rada, uz osvrt na pitanje da li Big Five podaci pokazuju postojanje diskretnih tipova ličnosti ili pre predstavljaju kontinuirani spektar osobina.