

Analiza strukture ličnosti primenom metoda klasterovanja

Projekat iz Istraživanja podataka 2 [R275]

Ksenija Ivanović 135/2019

Školska 2025/26 godina

Sadržaj

1	Uvod	3
1.1	Opis problema	3
1.2	Cilj rada	3
2	Opis podataka	4
2.1	Struktura upitnika	4
2.2	Dodatne promenljive	4
3	Metodologija	5
3.1	Priprema podataka	5
4	Pretprocesiranje podataka	5
4.1	Učitavanje i filtriranje podataka	5
4.2	Izbor relevantnih promenljivih	5
4.3	Standardizacija podataka	6
5	Redukcija dimenzionalnosti – PCA analiza	6
5.1	PCA bez vremenskih promenljivih	6
5.2	PCA sa vremenskim promenljivama	6
6	Algoritmi klasterovanja	7
6.1	Klasterovanje – KMeans	7
6.1.1	Rezultati klasterovanja	8
6.1.2	Evaluacija klastera	8
6.2	Hijerarhijsko klasterovanje – Agglomerative Clustering	9
6.2.1	Evaluacija klastera	9
6.3	Agglomerative Clustering sa single linkage metodom	11
6.4	Agglomerative Clustering – Complete linkage	12
6.5	DBSCAN analiza i uticaj parametra eps	15
6.6	Analiza raspodele klastera kod GMM modela	17
6.7	Spectral klasterovanje sa nearest-neighbors afinitetom	19
6.8	Spectral Clustering sa RBF afinitetom	21

7	Poređenje algoritama klasterovanja	22
7.1	Alternativni pristupi	23
7.1.1	Nelinearna redukcija dimenzionalnosti (UMAP)	23
7.1.2	Analiza trodimenzionalnih kombinacija subskala	23
8	Diskusija	24
9	Zaključak	25

1 Uvod

1.1 Opis problema

U ovom radu analiziramo podatke prikupljene putem Big Five Personality testa, jednog od najuticajnijih i empirijski najpotvrđenijih modela ličnosti u savremenoj psihologiji. Model opisuje ličnost kroz pet osnovnih dimenzija:


- Ekstraverzija (Extraversion)
- Neuroticizam (Neuroticism)
- Prijatnost (Agreeableness)
- Savesnost (Conscientiousness)
- Otvorenost ka iskustvu (Openness to Experience)

Svaka dimenzija meri se pomoću više tvrdnji koje ispitanici ocenjuju na Likertovoj skali (od 1 do 5). Agregacijom odgovora dobija se numerički skor koji predstavlja izraženost određene osobine kod pojedinca.

Iako se osobine ličnosti tradicionalno posmatraju kao kontinuirane dimenzije, postavlja se pitanje da li se ispitanici mogu prirodno grupisati u određene tipove ličnosti. Drugim rečima, da li u podacima postoji latentna struktura koja ukazuje na postojanje relativno stabilnih grupa pojedinaca sa sličnim profilima osobina?

Big Five Personality Test

Your Big Five scores are:



Slika 1: Primer prikaza rezultata Big Five testa

Ovaj rad ima za cilj da ispita postojanje takve strukture primenom metoda nenadgledanog učenja.

1.2 Cilj rada

Cilj rada je da se ispita da li se na osnovu odgovora na Big Five test može identifikovati prirodna segmentacija ispitanika.

Konkretnije, cilj je:

- utvrditi da li postoji jasno izražena klasterka struktura u podacima,
- uporediti performanse različitih algoritama klasterovanja,
- interpretirati dobijene klastere na osnovu prosečnih vrednosti osobina.

2 Opis podataka

Podaci koji se analiziraju prikupljeni su u periodu 2016–2018. godine putem interaktivnog onlajn testa ličnosti. Test je konstruisan na osnovu *Big-Five Factor Markers* iz IPIP baze (International Personality Item Pool).

Ispitanici su na početku testa informisani da će njihovi odgovori biti sačuvani i korišćeni u istraživačke svrhe, a na kraju su morali da potvrde saglasnost za korišćenje podataka. U dataset su uključeni isključivo ispitanici koji su dali saglasnost.

2.1 Struktura upitnika

Upitnik se sastoji od 50 tvrdnji, po 10 za svaku od pet dimenzija ličnosti:

- Ekstraverzija (EXT),
- Neuroticizam / Emocionalna stabilnost (EST),
- Saradljivost (AGR),
- Savesnost (CSN),
- Otvorenost ka iskustvu (OPN).

Svaka tvrdnja ocenjena je na petostepenoj Likertovoj skali:

$$1 = \text{Disagree}, \quad 3 = \text{Neutral}, \quad 5 = \text{Agree}.$$

Pored samih odgovora, zabeleženo je i vreme odgovaranja na svako pitanje (u milisekundama), što omogućava dodatne analize ponašanja ispitanika tokom popunjavanja testa.

2.2 Dodatne promenljive

Dataset sadrži i sledeće tehničke i kontekstualne informacije:

- `dateload` – vremenska oznaka početka testa,
- `introelapse`, `testelapse`, `endelapse` – vreme provedeno na pojedinim delovima testa,
- `IPC` – broj zapisa sa iste IP adrese (radi kontrole višestrukih unosa),
- `country` – zemlja korisnika (određena tehničkim putem),
- `screenw`, `screenh` – dimenzije ekrana,

- približne geografske koordinate (latitude i longitude), uz napomenu da ove vrednosti nisu precizne.

U okviru analize, primarni fokus biće na odgovorima na tvrdnje (50 stavki), dok će dodatne promenljive biti korišćene za filtriranje i inicijalnu obradu podataka (npr. uklanjanje višestrukih unosa korišćenjem promenljive IPC).

3 Metodologija

3.1 Priprema podataka

Pre primene algoritama klasterovanja izvršeni su sledeći koraci:

- Provera i uklanjanje nedostajućih vrednosti.
- Eventualna agregacija odgovora po dimenzijama.
- Skaliranje numeričkih podataka radi ujednačavanja opsega vrednosti.

Skaliranje je posebno važno jer većina algoritama klasterovanja koristi udaljenosti između tačaka, te različiti opsezi varijabli mogu značajno uticati na rezultate.

4 Pretprocesiranje podataka

Pre same primene algoritama klasterovanja izvršena je detaljna priprema podataka.

4.1 Učitavanje i filtriranje podataka

Podaci su učitani iz fajla `data-final.csv`, koji sadrži 1 015 341 ispitanika(redova) i 110 promenljivih(kolona).

Radi povećanja kvaliteta podataka, zadržani su samo ispitanici kod kojih je promenljiva IPC jednaka 1. Ova promenljiva označava broj zapisa sa iste IP adrese, te se njenim filtriranjem uklanjaju potencijalni višestruki unosi.

Nakon filtriranja, dataset je smanjen na 696 845 zapisa.

4.2 Izbor relevantnih promenljivih

Iz originalnog skupa podataka izdvojene su isključivo tvrdnje koje pripadaju pet dimenzija ličnosti (EXT, EST, AGR, CSN, OPN).

Prvo su izdvojene kolone koje predstavljaju same odgovore ispitanika (bez vremenskih oznaka odgovaranja, koje se završavaju sa _E). Time je dobijen skup od 50 promenljivih, odnosno po 10 za svaku dimenziju.

Nakon toga uklonjeni su redovi koji sadrže isključivo nedostajuće vrednosti. Nakon ovog koraka, dataset sadrži 695 704 ispitanika i 50 promenljivih.

Pored toga, formiran je i prošireni skup podataka koji uključuje i vremenske promenljive odgovaranja (kolone koje se završavaju sa _E). Na taj način dobijen je skup od 100 promenljivih, koji omogućava ispitivanje da li vreme odgovaranja utiče na formiranje klastera.

4.3 Standardizacija podataka

Pre primene algoritama klasterovanja izvršena je standardizacija svih numeričkih promenljivih korišćenjem metode Z-transformacije (StandardScaler).

Standardizacijom se svaka promenljiva transformiše tako da ima srednju vrednost 0 i standardnu devijaciju 1:

$$z = \frac{x - \mu}{\sigma}$$

Ovaj korak je neophodan jer algoritmi klasterovanja koriste mere udaljenosti između tačaka, te bi promenljive sa većim opsegom vrednosti imale veći uticaj na rezultat ukoliko ne bi bile skalirane.

Standardizacija je izvršena posebno za:

- skup od 50 psiholoških stavki,
- prošireni skup od 100 promenljivih (uključujući vreme odgovaranja).

5 Redukcija dimenzionalnosti – PCA analiza

Radi vizuelizacije strukture podataka primenjena je analiza glavnih komponenti (Principal Component Analysis – PCA).

PCA predstavlja metodu redukcije dimenzionalnosti kojom se originalne promenljive transformišu u novi skup međusobno nekorelisanih komponenti. Prva glavna komponenta (PC1) objašnjava najveći deo ukupne varijanse podataka, dok druga komponenta (PC2) objašnjava sledeći najveći deo varijanse.

U ovoj analizi izvršena je redukcija na dve glavne komponente, kako bi se omogućila dvodimenzionalna vizuelizacija podataka.


5.1 PCA bez vremenskih promenljivih

Prvo je PCA primenjena na standardizovani skup od 50 psiholoških stavki (bez vremenskih oznaka odgovaranja).

5.2 PCA sa vremenskim promenljivama

Zatim je ista procedura primenjena na prošireni skup podataka koji uključuje i vremenske promenljive odgovaranja (ukupno 100 promenljivih).

Na slici su prikazane projekcije ispitanika u prostoru prve dve glavne komponente za oba slučaja.



Slika 2: Poređenje PCA projekcija bez i sa vremenskim promenljivama

Sa slike se može primetiti:

- Projekcija bez vremenskih promenljivih prikazuje raspodelu ispitanika samo prema njihovim psihološkim osobinama.
- Projekcija sa vremenskim promenljivama može blago promeniti oblik klastera, ali u ovoj analizi vremenske promenljive nemaju dominantan uticaj.

Ovaj korak je važan jer nam omogućava da:

- vizuelno sagledamo da li se ispitanici prirodno grupišu,
- procenimo koliko vreme odgovaranja utiče na raspodelu u prostoru glavnih komponenti,
- pripremimo podatke za sledeći korak – primenu algoritama klasterovanja.

6 Algoritmi klasterovanja

U radu su primenjeni sledeći algoritmi:

- K-means klasterovanje
- Hijerarhijsko (agglomerativno) klasterovanje
- DBSCAN
- Spektralno klasterovanje

Za algoritme koji zahtevaju unapred definisan broj klastera testirano je više vrednosti parametra k , kako bi se procenila stabilnost rezultata.

6.1 Klasterovanje – KMeans

Da bismo istražili da li se ispitanici prirodno grupišu, primenili smo algoritam **KMeans** na standardizovane podatke.


Parametri: Broj klastera je postavljen na $k = 5$, sa `random_state=42` radi reproduktivnosti.

6.1.1 Rezultati klasterovanja

KMeans je primenjen na:

1. skup od 50 psiholoških stavki (bez vremenskih promenljivih),
2. prošireni skup od 100 promenljivih (uključujući vreme odgovaranja).

Labele klastera dodate su PCA DataFrame-ovima kako bismo mogli vizualizovati raspodelu u prostoru prve dve glavne komponente.



Slika 3: KMeans klasteri ($k = 5$) – poređenje bez i sa vremenskim promenljivama odgovaranja

6.1.2 Evaluacija klastera

Za ocenu kvaliteta klastera korišćene su sledeće metrike:

- **Silhouette score:** meri koliko su tačke unutar klastera slične, a između klastera različite.
- **Davies-Bouldin score:** niži skor označava bolje odvojene klasterove.
- **Calinski-Harabasz score:** veći skor označava bolje definisane klasterove.

Rezultati za uzorak od 15 000 ispitanika:

Skup podataka	Silhouette	Davies-Bouldin	Calinski-Harabasz
Bez vremenskih promenljivih	0.051	2.94	880.6
Sa vremenskim promenljivim	0.048	3.07	238.1

Tumačenje: Rezultati deluju loše jer algoritam KMeans forsira postojanje klastera čak i kada prirodno nisu jasno izraženi. To je tipično za podatke prikupljene po Big Five modelu, gde se osobine posmatraju kao kontinuirane dimenzije, a ne kao strogi tipovi ličnosti. Primetno je da uključivanje vremenskih promenljivih (`_E`) donekle menja raspodelu klastera, ali ne dramatično.

Napomena o broju klastera: Eksperimenti sa $k = 4$ mogu dati jasnije granice između klastera, jer peti klaster samo razblažuje centralne tačke.

6.2 Hijerarhijsko klasterovanje – Agglomerative Clustering

Pored algoritma KMeans, primenjen je i hijerarhijski pristup klasterovanju korišćenjem metode *Agglomerative Clustering* sa Ward-ovim kriterijumom spajanja.

Zbog velikog broja ispitanika (preko 600 000), algoritam je testiran na reprezentativnim uzorcima različitih veličina:

- $n = 2000$
- $n = 5000$
- $n = 10000$

Za svaki uzorak primenjeno je klasterovanje sa $k = 5$ klastera, posebno za:

1. skup bez vremenskih promenljivih (_E),
2. prošireni skup sa vremenskim promenljivama.

6.2.1 Evaluacija klastera

Vizuelizacija rezultata izvršena je projektovanjem podataka u prostor prve dve glavne komponente (PCA).

Uzorak $n=2000$:


Skup podataka	Silhouette	Davies-Bouldin	Calinski-Harabasz
Bez vremenskih promenljivih	0.022	3.36	82.0
Sa vremenskim promenljivim	0.030	2.99	81.8

Uzorak $n=5000$:

Skup podataka	Silhouette	Davies-Bouldin	Calinski-Harabasz
Bez vremenskih promenljivih	0.020	3.28	210.2
Sa vremenskim promenljivim	0.060	1.38	1083.6

Uzorak $n=10000$:

Skup podataka	Silhouette	Davies-Bouldin	Calinski-Harabasz
Bez vremenskih promenljivih	0.035	2.98	439.2
Sa vremenskim promenljivim	0.033	2.92	1661.9



Slika 4: Agglomerative Clustering ($k = 5$) za različite veličine uzorka – poređenje bez i sa vremenskim promenljivama

Projekcije podataka na prve dve glavne komponente (PCA) ukazuju na izraženo preklapanje između klastera u svim analiziranim uslovima (sa i bez uključivanja varijable vremena odgovaranja, pri različitim veličinama uzorka). Umesto jasno razdvojenih i kompaktnih grupa, uočava se kontinuirana distribucija tačaka sa postepenim prelazima između klastera.

Vrednosti Silhouette indeksa kreću se u rasponu od približno 0.02 do 0.06, što ukazuje na veoma slabu klstersku separaciju. Niske vrednosti ovog indeksa sugerišu da su posmatranja podjednako bliska susednim klasterima kao i sopstvenom klasteru, odnosno da ne postoji izražena prirodna segmentacija podataka.

Iako su u pojedinim uslovima zabeležene nešto povoljnije vrednosti Davies–Bouldin i Calinski–Harabasz indeksa, ta poboljšanja nisu praćena jasnim vizuelnim razdvajanjem grupa. Povećanje Calinski–Harabasz indeksa sa rastom veličine uzorka može se delimično objasniti njegovom osetljivošću na broj posmatranja, te se ne može tumačiti kao dokaz stabilne klsterske strukture.

Sa smanjenim brojem klastera ($k = 3$) primećeno je neznatno poboljšanje vrednosti Silhouette indeksa (maksimalno oko 0.07), međutim razlike u odnosu na rešenje sa većim brojem klastera nisu značajne i ne menjaju opšti obrazac rezultata.

6.3 Agglomerative Clustering sa single linkage metodom

Primena hijerarhijskog klasterovanja sa single linkage metodom dovela je do značajno viših vrednosti evaluacionih metrika u poređenju sa Ward-ovim kriterijumom.

U nastavku su prikazani rezultati za različite veličine uzorka.

Uzorak n=2000:


Skup podataka	Silhouette	Davies-Bouldin	Calinski-Harabasz
Bez vremenskih promenljivih	0.248	0.537	3.6
Sa vremenskim promenljivim	0.671	0.183	37.6

Uzorak n=5000:

Skup podataka	Silhouette	Davies-Bouldin	Calinski-Harabasz
Bez vremenskih promenljivih	0.243	0.551	3.4
Sa vremenskim promenljivim	0.806	0.086	958.0

Uzorak n=10000:

Skup podataka	Silhouette	Davies-Bouldin	Calinski-Harabasz
Bez vremenskih promenljivih	0.263	0.548	3.4
Sa vremenskim promenljivim	0.894	0.050	1388.2



Slika 5: Agglomerative Clustering ($k = 5$) za različite veličine uzorka – poređenje bez i sa vremenskim promenljivama

Dobijene vrednosti Silhouette indeksa pri single linkage metodi dostižu visoke vrednosti (0.67–0.89) u slučaju uključivanja vremenskih promenljivih. Ipak, vizuelna inspekcija ne potvrđuje postojanje jasno razdvojenih klastera.

Ovakav obrazac može se objasniti karakteristikama single linkage metode, koja je sklona formiranju jednog dominantnog klastera i nekoliko malih, udaljenih grupa (chaining efekat).

Evaluacione metrike mogu biti veštački poboljšane bez postojanja stabilne i interpretabilne klasterne strukture.

U tom smislu, rezultati dobijeni Ward-ovim kriterijumom smatraju se pouzdanijim pokazateljem stvarne strukture podataka.

6.4 Agglomerative Clustering – Complete linkage

Rezultati complete linkage metode prikazani su za tri veličine uzorka ($n=2000$, 5000 i 10000), sa i bez vremenskih promenljivih.

Uzorak $n=2000$:

Skup podataka	Silhouette	Davies-Bouldin	Calinski-Harabasz
Bez vremenskih promenljivih	0.022	3.165	70.1
Sa vremenskim promenljivim	0.671	0.183	37.6

Tabela 1: Complete linkage – n=2000

Uzorak n=5000:

Skup podataka	Silhouette	Davies-Bouldin	Calinski-Harabasz
Bez vremenskih promenljivih	0.018	3.860	145.0
Sa vremenskim promenljivim	0.806	0.086	958.0

Tabela 2: Complete linkage – n=5000

Uzorak n=10000:


Skup podataka	Silhouette	Davies-Bouldin	Calinski-Harabasz
Bez vremenskih promenljivih	0.035	3.300	261.4
Sa vremenskim promenljivim	0.863	0.288	1422.2

Tabela 3: Complete linkage – n=10000

Kod modela bez vremenskih promenljivih, vrednosti Silhouette indeksa ostaju veoma niske (0.018–0.035), dok je Davies-Bouldin indeks visok (3.165–3.860), što ukazuje na slabu separaciju i značajno preklapanje klastera. Vizuelna analiza PCA projekcije potvrđuje odsustvo jasno definisane klusterske strukture.

Nasuprot tome, uključivanje vremenskih promenljivih dovodi do značajnog poboljšanja svih validacionih metrika. Silhouette indeks dostiže vrednosti između 0.671 i 0.863, dok Davies-Bouldin indeks opada ispod 0.3. Calinski-Harabasz indeks pokazuje snažan rast sa povećanjem veličine uzorka, što ukazuje na stabilniju i kompaktniju klustersku strukturu.

Međutim, vizuelna analiza sugeriše postojanje jednog dominantnog klastera uz nekoliko manjih grupa, što može ukazivati na neravnomernu distribuciju veličina klastera karakterističnu za complete linkage metodu.



Slika 6: Agglomerative Clustering ($k = 5$) za različite veličine uzorka – poređenje bez i sa vremenskim promenljivama

Zaključak aglomerativne metode U okviru hijerarhijskog klasterovanja analizirane su tri varijante aglomerativne metode: Ward, Single i Complete linkage. Rezultati pokazuju značajne razlike u stabilnosti i kvalitetu formiranih klastera.

Single linkage metoda pokazala je izražen chaining efekat za sve veličine uzorka i oba skupa podataka. Gotovo ceo skup podataka svrstavan je u jedan dominantan klaster, dok su preostali klasteri sadržali pojedinačne ili veoma mali broj instanci. Iako su pojedine validacione metrike bile visoke, distribucija klastera ukazuje na neadekvatnu segmentaciju podataka.

Complete linkage metoda, bez vremenskih promenljivih, formira relativno uravnoteženije klasterne, uz prisustvo manjih izolovanih grupa. Uključivanjem vremenskih promenljivih dolazi do izražene neravnoteže, gde jedan klaster obuhvata gotovo sve instance, dok su ostali klasteri minimalne veličine, što sugeriše ograničenu robusnost metode.

Ward metoda pokazala je najveći stepen stabilnosti. Bez vremenskih promenljivih klasteri su relativno ravnomerno raspoređeni kroz sve veličine uzorka. Kod modela sa vremenskim promenljivim pojavljuju se manji izolovani klasteri, ali raspodela ostaje značajno uravnoteženija u poređenju sa Single i Complete metodama.

Na osnovu analize validacionih metrika i distribucije veličina klastera može se zaklju-

čiti da Ward metoda predstavlja najstabilniji i metodološki najopravdaniji izbor unutar aglomerativnog pristupa za analizirani skup podataka.

6.5 DBSCAN analiza i uticaj parametra eps

DBSCAN metoda analizirana je za različite vrednosti parametra eps (5.5, 1.5 i 0.5) i četiri veličine uzorka.

Pri vrednosti eps=5.5 formira se jedan dominantan klaster uz značajan broj instanci klasifikovanih kao šum (noise). U pojedinim slučajevima javljaju se i veoma mali klasteri sa svega nekoliko instanci. Međutim, validacione metrike (niske ili negativne vrednosti Silhouette indeksa i visoke vrednosti Davies-Bouldin indeksa) ukazuju na slabu separaciju klastera.

Smanjenjem parametra eps na 1.5 i 0.5 dolazi do gotovo potpunog kolapsa klasterne strukture, pri čemu su gotovo sve instance označene kao šum. Ovo ukazuje na odsustvo jasno definisanih lokalnih gustinskih regiona u podacima.

Rezultati su gotovo identični za skupove sa i bez vremenskih promenljivih, što sugerise da vremenske promenljive ne utiču značajno na lokalnu gustinsku strukturu podataka.

Na osnovu dobijenih rezultata može se zaključiti da DBSCAN metoda nije adekvatna za analizirani skup podataka, s obzirom na kontinuiranu distribuciju i odsustvo jasno razdvojenih gustinskih oblasti.

Skup podataka	Silhouette	Davies-Bouldin	Calinski-Harabasz
Bez vremenskih promenljivih	-0.100	7.706	2.4
Sa vremenskim promenljivim	-0.109	7.957	2.0

Tabela 4: DBSCAN (eps=5.5) – n=500

Skup podataka	Silhouette	Davies-Bouldin	Calinski-Harabasz
Bez vremenskih promenljivih	0.008	7.430	26.6
Sa vremenskim promenljivim	0.005	7.591	24.4


Tabela 5: DBSCAN (eps=5.5) – n=2000

Skup podataka	Silhouette	Davies-Bouldin	Calinski-Harabasz
Bez vremenskih promenljivih	0.033	6.367	84.7
Sa vremenskim promenljivim	-0.011	5.308	30.7


Tabela 6: DBSCAN (eps=5.5) – n=5000

Skup podataka	Silhouette	Davies-Bouldin	Calinski-Harabasz
Bez vremenskih promenljivih	0.032	4.309	83.7
Sa vremenskim promenljivim	0.032	4.446	48.7

Tabela 7: DBSCAN (eps=5.5) – n=10000



Slika 7: DBSCAN ($eps = 5.5$) za različite veličine uzorka – poređenje bez i sa vremenskim promenljivama



Slika 8: DBSCAN ($eps = 0.5$) za različite veličine uzorka – poređenje bez i sa vremenskim promenljivama

6.6 Analiza raspodele klastera kod GMM modela

Analizom raspodele instanci po klasterima u okviru Gaussian Mixture Model (GMM) algoritma uočene su značajne razlike između modela sa osnovnim skupom atributa i modela proširenog dodatnim `_E` atributima.

Kod modela bez `_E` atributa raspodela instanci po klasterima bila je relativno uravnotežena za sve veličine uzorka (2000, 5000 i 15000 slogova). Ovakvi rezultati ukazuju da model formira komponente približno sličnih veličina, ali bez jasne separacije, što potvrđuju vrlo niske vrijednosti Silhouette indeksa (0).

Međutim, kod modela sa `_E` atributima primećena je izražena degeneracija modela. Već kod uzorka od 2000 slogova jedan klaster sadrži samo jednu instancu, dok dominantni klaster obuhvata većinu podataka. Ovaj efekat se dodatno pojačava sa povećanjem veličine uzorka. Kod uzorka od 15000 slogova raspodela iznosi [14997, 1, 2], što znači da gotovo sve instance pripadaju jednom klasteru, dok preostale komponente sadrže zanemarljiv broj instanci.

Takvo rešenje predstavlja kolaps komponenti u GMM modelu (component collapse), pri čemu jedna Gaussova komponenta preuzima gotovo celu raspodelu podataka, dok ostale postaju numerički nestabilne. Iako ovakvo rešenje može rezultovati visokim vred-

nostima indeksa kao što je Silhouette koeficijent, ono ne predstavlja smisleno klstersko razdvajanje.

Dobijeni rezultati ukazuju da povećanje dimenzionalnosti skupa atributa može dovesti do nestabilnosti procene kovarijacionih matrica u GMM modelu, posebno kod velikih uzoraka, što za posledicu ima degeneraciju klsterske strukture.

Testiranje većeg broja komponenti nije dovelo do poboljšanja kvaliteta klstera. Kod modela bez $_E$ atributa metrika ostaje bliska nuli, dok kod modela sa $_E$ atributima dolazi do izraženog kolapsa komponenti pri većim uzorcima, čime se potvrđuje nestabilnost GMM modela u ovom skupu podataka.

Skup podataka	Silhouette	Davies-Bouldin	Calinski-Harabasz
Bez vremenskih promenljivih	0.004	7.020	39.2
Sa vremenskim promenljivim	0.035	13.263	9.3


Tabela 8: GMM (k=3) – n=2000

Skup podataka	Silhouette	Davies-Bouldin	Calinski-Harabasz
Bez vremenskih promenljivih	0.002	9.045	88.3
Sa vremenskim promenljivim	0.056	14.550	1567.1

Tabela 9: GMM (k=3) – n=5000

Skup podataka	Silhouette	Davies-Bouldin	Calinski-Harabasz
Bez vremenskih promenljivih	-0.001	9.946	283.4
Sa vremenskim promenljivim	0.973	0.133	2633.8

Tabela 10: GMM (k=3) – n=15000



Slika 9: GMM ($k = 3$) za različite veličine uzorka – poređenje bez i sa vremenskim promenljivama

6.7 Spectral klasterovanje sa nearest-neighbors afinitetom

Primena Spectral Clustering algoritma sa parametrom *affinity* = *nearest_neighbors* i brojem klastera $k = 5$ pokazuje stabilnije ponašanje u odnosu na GMM model.

Za uzorak od $n = 2000$ dobijene su vrednosti Silhouette indeksa od približno 0.05, uz Davies-Bouldin indeks oko 3 i umerene vrednosti Calinski-Harabasz indeksa. Slični rezultati dobijeni su i za $n = 5000$, pri čemu se Silhouette indeks blago povećava (0.055), dok DB indeks ostaje umeren.

Raspodela instanci po klasterima je relativno uravnotežena, bez pojave kolapsa komponenti, što ukazuje na numeričku stabilnost algoritma.

Međutim, vrednosti Silhouette indeksa ostaju niske (0.05), što ukazuje da klasteri nisu jasno razdvojeni u prostoru atributa. Vizuelna inspekcija PCA projekcija potvrđuje značajno preklapanje klastera.


Dobijeni rezultati sugerišu postojanje slabe lokalne strukture podataka, ali bez izražene diskretne klasterske separacije.

Skup podataka	Silhouette	Davies-Bouldin	Calinski-Harabasz
Bez vremenskih promenljivih	0.053	2.972	110.9
Sa vremenskim promenljivim	0.052	3.015	101.1

Tabela 11: Spectral clustering ($k=5$) – $n=2000$

Skup podataka	Silhouette	Davies-Bouldin	Calinski-Harabasz
Bez vremenskih promenljivih	0.055	2.604	285.9
Sa vremenskim promenljivim	0.057	2.684	139.5

Tabela 12: Spectral clustering ($k=5$) – $n=5000$



Slika 10: Spectral clustering ($k = 5$) za različite veličine uzorka – poređenje bez i sa vremenskim promenljivama

6.8 Spectral Clustering sa RBF afinitetom

U ovom delu istraživanja primenjen je Spectral Clustering sa RBF (gaussovskim) afinitetom za različite vrednosti parametra γ (0.1, 0.25 i 0.5) i veličine uzorka (1000 i 2000 slogova).

Rezultati pokazuju izrazitu nestabilnost modela, naročito kod proširenog skupa atributa (sa _E promenljivama).

Za manje vrednosti parametra γ primećena je velika neravnoteža klastera, dok sa povećanjem γ dolazi do potpunog kolapsa modela, gde gotovo svi slogovi bivaju dodeljeni jednom dominantnom klasteru, uz pojavu nekoliko izolovanih jedinica.


Primer raspodele klastera za $\gamma = 0.5$ i $n = 2000$:

- Bez _E: [1966, 2, 1, 14, 17]
- Sa _E: [0, 1, 1999]


Ovakva struktura ukazuje da podaci nemaju izraženu nelinearnu klasteru strukturu koju Spectral Clustering može da detektuje.

Vizuelna analiza PCA projekcija potvrđuje da slogovi formiraju gust kontinuiran oblak bez jasno razdvojenih grupa.


Može se zaključiti da primena RBF afiniteta u ovom slučaju ne doprinosi identifikaciji stabilnih i interpretabilnih klastera.



Slika 11: Spectral clustering ($k = 5$) sa rbf afinitetom ($\gamma = 0.1$) za različite veličine uzorka – poređenje bez i sa vremenskim promenljivama



Slika 12: Spectral clustering ($k = 5$) sa rbf afinitetom ($\gamma = 0.25$) za različite veličine uzorka – poređenje bez i sa vremenskim promenljivama



Slika 13: Spectral clustering ($k = 5$) sa rbf afinitetom ($\gamma = 0.5$) za različite veličine uzorka – poređenje bez i sa vremenskim promenljivama

7 Poređenje algoritama klasterovanja

U okviru eksperimentalnog dela rada testirani su sledeći algoritmi klasterovanja: K-means, hijerarhijsko klasterovanje (Agglomerative, Ward metoda), DBSCAN, Gaussian

Mixture Model (GMM) i Spectral Clustering sa RBF jezgrom.

Evaluacija kvaliteta klastera izvršena je korišćenjem internih metrika: Silhouette koeficijenta, Davies–Bouldin (DB) indeksa i Calinski–Harabasz (CH) indeksa.

7.1 Alternativni pristupi


7.1.1 Nelinearna redukcija dimenzionalnosti (UMAP)

Kako primena linearne redukcije dimenzionalnosti pomoću PCA nije rezultirala jasnom separacijom klastera, u daljoj analizi ispitana je mogućnost postojanja nelinearne strukture podataka. U tu svrhu primenjena je metoda Uniform Manifold Approximation and Projection (UMAP), koja omogućava očuvanje lokalne geometrije podataka i potencijalno bolje razdvajanje grupa u slučaju nelinearnih odnosa između promenljivih.

UMAP projekcija izvršena je nad standardizovanim podacima, pri čemu je broj dimenzija reduciran na dve radi vizuelne interpretacije. Analiza je sprovedena za obe varijante skupa podataka (sa i bez dodatne varijable `_E`), kako bi se ispitalo da li uključivanje dodatne informacije doprinosi jasnijoj strukturi prostora.

Vizuelizacija u dvodimenzionalnom UMAP prostoru nije pokazala značajno izraženiju separaciju grupa u odnosu na rezultate dobijene PCA metodom. Podaci su formirali dominantnu, kompaktnu strukturu sa manjim brojem izdvojenih tačaka, bez jasnih granica između potencijalnih klastera. Uvođenje dodatne varijable `_E` nije dovelo do vidljive diferencijacije grupa, već je projekcija postala još kompaktnija.

Dobijeni rezultati sugerišu da ograničena separacija klastera nije posledica linearne prirode PCA metode, već verovatno odražava inherentnu strukturu samog skupa podataka. Drugim rečima, analiza nije ukazala na postojanje izražene nelinearne strukture koja bi omogućila jasnije razdvajanje klastera u niskodimenzionalnom prostoru.



Slika 14: Poređenje PCA projekcija bez i sa vremenskim promenljivama

7.1.2 Analiza trodimenzionalnih kombinacija subskala

Kako bi se dodatno ispitala potencijalna struktura podataka u nižedimenzionalnim prostorima, izvršena je analiza svih kombinacija po tri sumarne subskale (EXT, EST, AGR, CSN, OPN). Za svaku od $\binom{5}{3} = 10$ mogućih trodimenzionalnih kombinacija primenjen je K-means algoritam sa unapred definisanim brojem klastera ($k = 3$).


Podaci su prethodno standardizovani, a analiza je sprovedena nad reprezentativnim uzorkom radi stabilnosti i preglednosti vizuelizacije. Za svaku kombinaciju izračunata je Silhouette mera u cilju procene kvaliteta klsterske separacije.

Dobijene vrednosti Silhouette koeficijenta kretale su se u intervalu približno od 0.24 do 0.26, što ukazuje na slabu separaciju klastera i značajno preklapanje između grupa. Vizuelna inspekcija 3D projekcija dodatno potvrđuje ovaj nalaz: podaci formiraju dominantnu, kompaktnu strukturu bez jasno izraženih granica između potencijalnih klastera, uz prisustvo manjeg broja izdvojenih tačaka (outliera).

Dodatno je ispitana i varijanta sa dva klastera ($k = 2$), pri čemu su dobijene visoke vrednosti Silhouette koeficijenta (0.8). Međutim, detaljna analiza pokazuje da se u tom slučaju jedan klaster sastoji gotovo od celokupnog skupa podataka, dok drugi obuhvata mali broj ekstremnih vrednosti. Takva struktura ukazuje na izolaciju outliera, a ne na postojanje dve stabilne i interpretabilne grupe.


Rezultati ove analize sugerišu da u trodimenzionalnim podprostorima sumiranih osobina ne postoji izražena prirodna segmentacija podataka. Uočena struktura više odgovara kontinuumu osobina nego postojanju diskretnih tipova.

Kombinacija: ('EXT_sum', 'EST_sum', 'AGR_sum')
Silhouette=0.256



(a)

Kombinacija: ('EXT_sum', 'EST_sum', 'CSN_sum')
Silhouette=0.258



(b)

Slika 15: Primeri trodimenzionalnih kombinacija subskala za ($k = 3$)

8 Diskusija

U ovom delu rada razmatra se:

- Da li postoji jasna prirodna struktura u podacima.
- Koliko su klasteri stabilni i interpretabilni.
- Ograničenja primenjenog pristupa.

9 Zaključak

U zaključku će biti sumirani ključni nalazi rada, uz osvrt na pitanje da li Big Five podaci pokazuju postojanje diskretnih tipova ličnosti ili pre predstavljaju kontinuirani spektar osobina.